

Universidad Nacional de San Agustín

Unidad de Postgrado de la Facultad de Producción y Servicios



Maestría en Ciencias de la computación

TRABAJO FINAL: Un enfoque de aprendizaje automático para el reconocimiento de cortes conformes y no conformes en imágenes.

**Docente: Dr. Juan Carlos Gutiérrez
Cáceres**

**Christian Néstor Barriga Marcapura
Weimar Ccapatinta Huamani**

2023

1. INTRODUCCIÓN

La clasificación de los cortes de carne es un proceso crítico en la industria de la carne y en la cadena de suministro de alimentos en general. Los cortes de carne deben ser clasificados con precisión para garantizar la calidad del producto y satisfacer las demandas del mercado. A medida que la producción de carne se vuelve cada vez más automatizada, se ha vuelto importante desarrollar sistemas de clasificación más eficientes y precisos utilizando tecnologías como la inteligencia artificial (IA).

La IA puede mejorar significativamente la clasificación de los cortes de carne al permitir la identificación automática de características importantes y la clasificación precisa en tiempo real. La capacidad de la IA para analizar grandes cantidades de datos también la hace útil para mejorar la eficiencia y la precisión de la clasificación.

En este trabajo se presenta un algoritmo para la detección de patrones que hacen a un producto No Conforme, utilizando máquinas tradicionales.

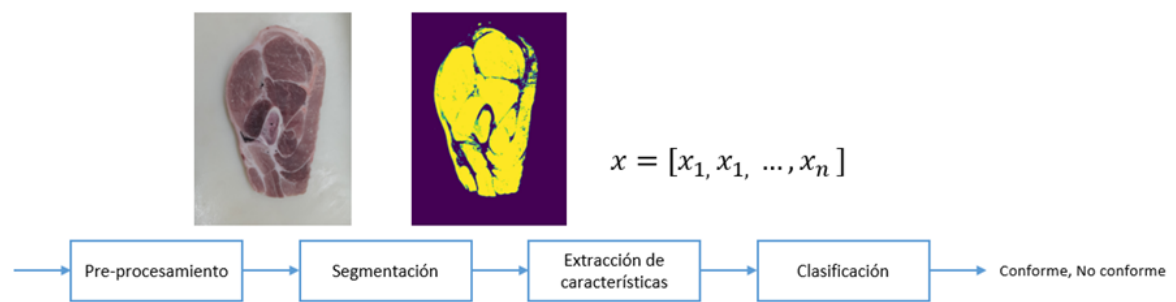
Se propone un aprendizaje y un trabajo artesanal, contando con un preprocesado que reduce las sombras en la imagen producidas por la circularidad de algunas partes del cuerpo. En segundo lugar, se segmenta el corte de la superficie utilizando el algoritmo de aprendizaje no supervisado: Gaussian Mixture Model. Posteriormente, se calculan características basadas en un criterio de calidad del producto, que se utiliza para si un corte es No conforme, y finalmente se realiza una clasificación. Las principales contribuciones de este trabajo son: (i) La implementación de un novedoso sistema de reconocimiento de patrones que trabaja sobre imágenes. (ii) La comparación del rendimiento del modelo de mezcla gaussiana para segmentar diferentes tipos de lesiones cutáneas. (iii) Un estudio sobre el impacto del método de aumento de datos Smoothed Bootstrap en el rendimiento de diferentes topologías de clasificadores.

2. MÉTODO DE INVESTIGACIÓN

Para detectar patrones que hacen que un corte sea no conforme, el sistema se basa en un criterio de los expertos en calidad de producto. Estos son asimetría, borde, color y diferencias estructurales [6]. Asimetría (A): Se genera por los cortes que provienen de los extremos de las piezas las cuales no son asimétricas por la naturaleza del corte. Fronteras (B): los cortes no conformes son irregulares. Por el contrario, los cortes conformes tienden a tener bordes que se difuminan suavemente y son simétricos. Color (C): El color del corte viene a ser más oscuro que su superficie ya que dicha superficie es una faja transportadora de color blanco.

En la implementación se utilizó un data set de fotografías tomadas en producción, que contiene 202 imágenes de dos tipos, Conformes (81) y No Conformes (121). Este conjunto de datos se utilizó para entrenar el sistema. Sin embargo, es claro que no es tan grande para asegurar la significancia estadística, sin embargo, dado que los conjuntos de datos.

En la siguiente Figura se muestra el diagrama de bloques del sistema propuesto. Todo el sistema se implementó en Python, utilizando la biblioteca OpenCV para el paso de preprocesamiento, así como para la extracción de funciones. Por otro lado, para la clasificación se utilizaron las bibliotecas Scikit-learn y Tensorflow 2.




2.1. Preprocesamiento

En este bloque se atenúan las sombras, provocadas por la persona que tomo las fotos. Para corregir este problema, se crea otra imagen, obtenida de la regresión de los valores cerca de los costados de la imagen original.

2.2. Segmentación


El propósito de este paso es detectar el corte de chuleta automáticamente en función de la distribución del color de la imagen. Utilizaremos el método de Otsu que puede describir adecuadamente la distribución de color de la imagen y obtener los parámetros de cada uno de los dos grupos para realizar una clasificación por píxeles.



2.3. Características basadas en el criterio del departamento de calidad del producto


2.3.1. Funciones basadas en la asimetría

Por naturaleza del corte los extremos presentan formas asimétricas considerando también el proceso de congelado donde como resultado de la presión entre piezas hace que dichas partes extremas mantengan formas asimétricas.




2.3.2. Imagen de información de variación de textura, oscuridad y color


Para características basadas en bordes, uniformidad de color y estructuras, Se crean tres canales, obtenidos a partir de la imagen original. El primer canal proporciona información sobre la Variación de textura, la segunda sobre la oscuridad de la piel, y la tercera, información sobre la variación de color




Original



variación de textura




información de oscuridad



Color información

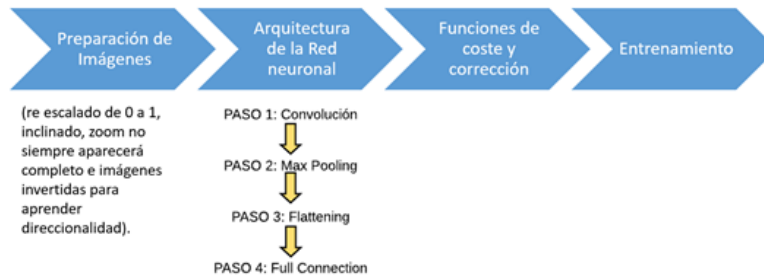
La siguiente figura muestra el espacio de características donde cada característica va a ser un canal (textura, oscuridad y color), donde cada punto sería una imagen,




3. RESULTADOS Y DISCUSIÓN

Por otro lado, a lo largo de los años se han propuesto sistemas tradicionales de aprendizaje automático y aprendizaje profundo, en esta ocasión la metodología de entrenamiento lo podemos apreciar en la siguiente imagen, la cual realiza todo lo detallado anteriormente.

Metodología



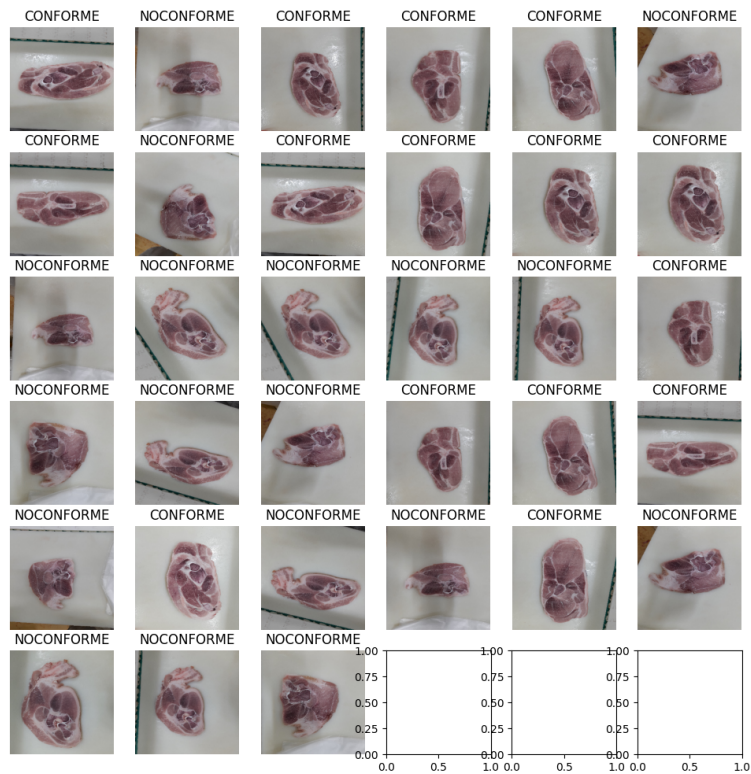
Los detalles de los cuatro pasos de la arquitectura de redes neuronales se muestran en la siguiente imagen.




El desarrollo se realizó en base a un modelo pre-entrenado ResNet50 el cual contiene las siguientes características:

```
=====
Total params: 23,587,712
Trainable params: 23,534,592
Non-trainable params: 53,120
=====
```

La implementación se utilizó un data set (“entrenamiento” y “test”) de fotografías tomadas en producción clasificadas en Conformes (81) y No Conformes (121). a continuación una muestra



A continuación la siguiente gráfica muestra la precisión obtenida en el proceso de entrenamiento.



La precisión obtenida en la evaluación fue de 56 % lo que hace que la predicción falle sobre todo en los cortes No conformes.



4. CONCLUSIONES

En primer lugar, se deduce que el sistema desarrollado en machine learning tradicional es una herramienta fiable porque tiene un 80% de precisión, pero a su vez este sistemas es más complejo por que se tiene que extraer las características una a una y no escalable, por ello la utilización de redes neuronales ayudan a que sea más efectiva.

La precisión del modelo de redes neuronales fue de 56%, lo cual es resultado de la baja cantidad de imágenes entrenadas. y la variedad de formas que tienen las imágenes de cortes no conformes los cuales podrían tener una sub clasificación.

REFERENCIAS

[1] Jairo Hurtado, Francisco Reales, "A machine learning approach for the recognition of melanoma skin cancer on macroscopic images"